# TALLER 1: ANÁLISIS PREDICTIVO Y APRENDIZAJE ESTADÍSTICO

Caso de Estudio: Advertising Data

Elkin Daniel Ramos Rodríguez
78158
Valentina Zarate Perdomo
114109

Universidad ECCI

DOCENTE
Fredy Alexander Orjuela López

SISTEMAS AVANZADOS DE PRODUCCIÓN
INGENIERIA INDUSTRIAL

7 DE MARZO DE 2026
BOGOTA, COLOMBIA

# Contenido

**Introducción** 2

**Descripción de las variables** 3

**Estadística descriptiva y análisis exploratorio** 3

- **Carga y preparación de datos** 3
- **Caracterización numérica** 4
- **Análisis de distribución y atípicos** 4
  - **Simetría de la distribución de la TV** 5
  - **Simetría de la distribución de la radio** 5
  - **Simetría de la distribución de Newspaper** 5

## Introducción

La cuestión del impacto de la inversión publicitaria en las ventas se ha convertido en uno de los interrogantes más habituales del análisis de negocio, adentrándose en el ámbito de la capacidad de tomar decisiones basadas en datos. La empresa desea conocer el grado de relación entre la inversión publicitaria y el éxito comercial, toda vez que conocer tal relación puede ayudar a una mejor asignación de recursos a la hora de optar por determinado enfoque de marketing, así como mejorar el rendimiento comercial en multitud de mercados.

El conjunto de datos Advertising permite realizar tal ejercicio de estimación de una relación entre registros de ventas en 200 mercados diferentes y presupuestos en los que se distribuyen esas ventas para tres canales de comunicación: televisión, radio y prensa. Permite tener una idea de cuál es la influencia que pueden tener las diferentes inversiones en medios publicitarios sobre el comportamiento de las ventas y qué grado de importancia tiene cada uno de los canales de comunicación a la hora de definir una estrategia promocional.

En esta línea de trabajos, el presente taller pretende permitir el desarrollo de ciertas habilidades analíticas en la dirección de determinar si existe o no una relación de dependencia entre la inversión publicitaria y el éxito comercial y cuál es esa pendiente de la relación (u otro parámetro al que se le encuentre interés). Al mismo tiempo, se trata de evaluar el rendimiento predictivo de los diferentes modelos estadísticos a partir del uso de herramientas de análisis de datos que permiten la interpretación de los resultados y que pueden contribuir a la toma de decisiones basada en datos.

## Descripción de las variables

En esta fase se llevó a cabo la lectura del dataset, la preparación del conjunto de razones y la elección de las variables que se estimaron mediante Regresión Lineal Simple. El conjunto de datos contiene información sobre ventas en 200 mercados y la información de publicidad en TV, radio y periódico. Para el análisis se ha querido considerar como variable independiente el presupuesto en TV y como variable dependiente las ventas. Pero también se ha hecho un control de calidad de los datos, eliminando columnas irrelevantes, confirmando que las variables fueran numéricas, revisando que no hiciesen falta valores que podrían influir negativamente en el análisis estadístico.

## Estadística descriptiva y análisis exploratorio

## Carga y preparación de datos

*Ilustración 1cargue del archivo*

Se realiza cargue del archivo que se encuentra en GitHub en el repositorio de semana 3 y mediante Colab de Google, en donde se configura el entorno y carga de librerías como: manipulación de datos, visualización, estadística descriptiva y modelo predictivo. Son estas librerías que se utilizaran para el desarrollo de esta actividad.

**Caracterización numérica**

*Tabla 1 medidas de tendencia central y dispersión para las variables independientes y la variable de ventas dependiente*

| Variable | Media (Mean) | Mediana (Median) | Desv. Estándar (Std) | Mínimo (Min) | Máximo (Max) | Asimetría (Skewness) | Curtosis (Kurtosis) |
|---|---|---|---|---|---|---|---|
| TV | 147.0425 | 149.75 | 85.854236 | 0.7 | 296.4 | -0.069853 | -1.226495 |
| Radio | 23.2640 | 22.90 | 14.846809 | 0.0 | 49.6 | 0.094175 | -1.260401 |
| Newspaper | 30.5540 | 25.75 | 21.778621 | 0.3 | 114.0 | 0.894720 | 0.649502 |
| Sales | 14.0225 | 12.90 | 5.217457 | 1.6 | 27.0 | 0.407571 | -0.408869 |

**Análisis de distribución y atípicos**

El coeficiente de asimetría (o skewness) es una medida estadística que expresa hasta qué punto está asimétrica (o sesgada) una distribución de datos respecto de su media, es decir, nos indica hacia qué lado se "tira" la distribución.

$$Skewness \approx 0 \rightarrow Distribución\ aproximadamente\ simétrica$$

$$Skewness > 0 \rightarrow Sesgo\ positivo\ (cola\ hacia\ la\ derecha\ ) Skewness < 0 \rightarrow Sesgo\ negativo\ (cola\ hacia\ la\ izquierda\ )$$

Entonces con esto, tenemos en cuenta la regla práctica:

$$|Skew| < 0{,}5 \rightarrow Aproximadamente\ simétrica$$

$$0{,}5 \leq |Skew| < 1 \rightarrow Moderadamente\ sesgada$$

$$|Skew| \geq 1 \rightarrow \ Altamente\ sesgada$$

**Simetría de la distribución de la TV**

Existe una **correlación positiva fuerte entre la inversión en publicidad en TV y las ventas (r = 0.78)**, lo que indica que a medida que aumenta la inversión en televisión, las ventas tienden a incrementarse.

**Simetría de la distribución de la radio**

Existe una **correlación positiva moderada entre la inversión en publicidad en radio y las ventas (r = 0.58)**, lo que indica que, al aumentar la inversión en radio, las ventas tienden a incrementarse, aunque en menor medida que con la publicidad en televisión.

**Simetría de la distribución de Newspaper**

Presenta **asimetría positiva moderada (skewness = 0.8947)**, lo que indica que la distribución se inclina hacia la derecha debido a la presencia de algunos valores altos que extienden la cola en ese sentido.

**Exploración de la Nube de Puntos**

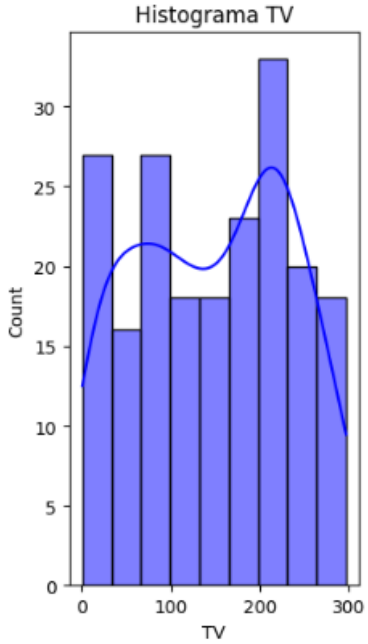


*Ilustración 2 histograma tv*

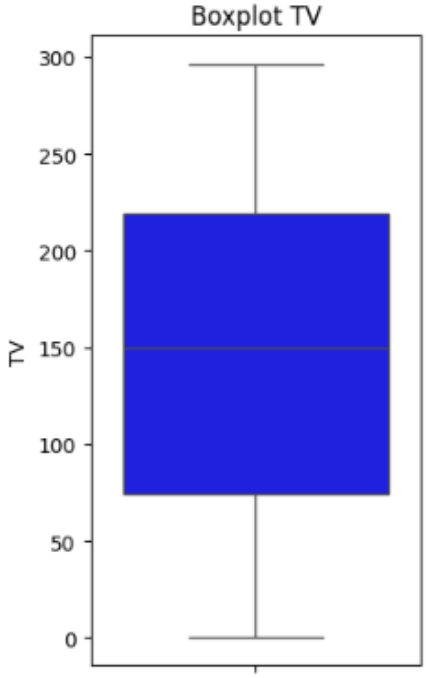


*Ilustración 3 boxplor TV*

En cuanto a la representación visual, la distribución de la variable TV ofrece una distribución bastante dispersa en todos los valores que se observan. El histograma denota una distribución que puedes describirse como simétrica, con una pequeña concentración de la distribución en los valores medios; el boxplot muestra que no hay valores extremos atípicos. En general, no se observan patrones complejos como curvaturas, segmentos diferenciados, o datos influénciales en la variable dependiente que sugieran que una relación con otras variables sólo podría aproximarse mediante un modelo lineal simple.

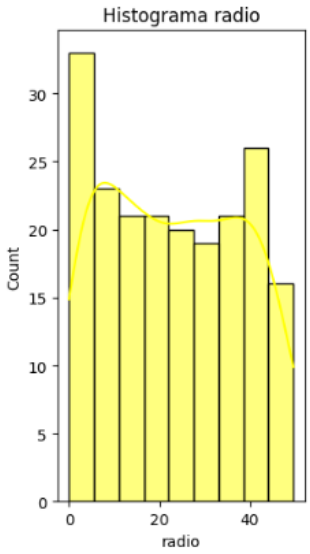


*Ilustración 4  histograma radio*

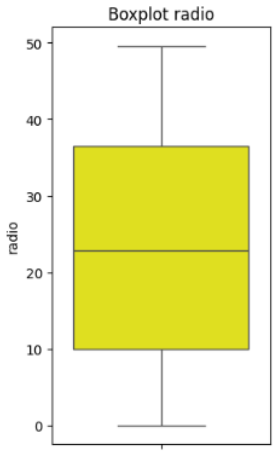


*Ilustración 5  boxplot radio*

En cuanto a aspectos visuales, podemos decir que la variable radio mantiene una distribución relativamente equilibrada, aunque muy concentrada, con la mayor parte de los valores dentro de los rangos intermedios. El histograma muestra una distribución no muy marcada, sin picos extremos y el boxplot indica que los datos están en el rango esperado; no aparecen valores atípicos relevantes. En global, la longitud de los datos es moderada y no hay evidencias suficientes

de patrones complejos, por lo que podría ser que esta variable mantenga una relación aproximadamente lineal con otras variables de modelo.

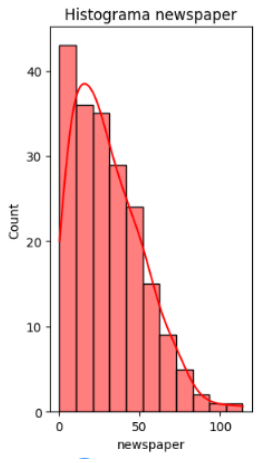


*Ilustración 6 histograma newspaper*

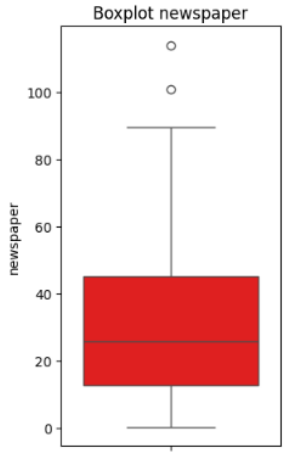


*Ilustración 6 boxplot newspaper*

La variable newspaper presenta una distribución con asimetría positiva, dado que el histograma denota una gran acumulación de valores bajos y una cola hacia la derecha. La representación gráfica por cajas apoya esta idea, puesto que se observan algunos outliers altos, que denotan algunos casos con inversión en periódicos mucho más alta que los otros valores. A grandes rasgos, esta gran dispersión es indicativa de que la variable newspaper puede contener datos

influyentes, afirmación que queda corroborada por una relación que podría no ser completamente lineal con respecto a otras variables del problema.

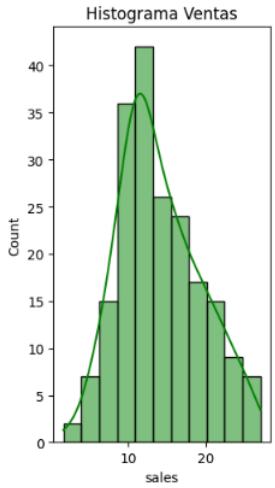


*Ilustración 7 histograma ventas*

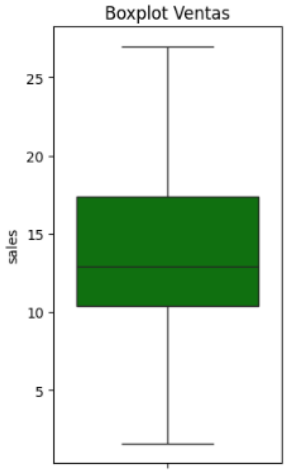


*Ilustración 8 boxplot ventas*

La serie temporal sales presenta una forma aproximadamente normal notando que el histograma presenta una forma relativamente simétrica, además, mayor concentración de datos en los valores medios. El boxplot muestra que la mayoría de las observaciones se encuentran

concentradas en un rango moderado y no se observen atípicos importantes. En general, la distribución refleja un comportamiento estable de las ventas y no se observan patrones definidos.

**Evaluación de Asociación**

**coeficiente de Pearson**

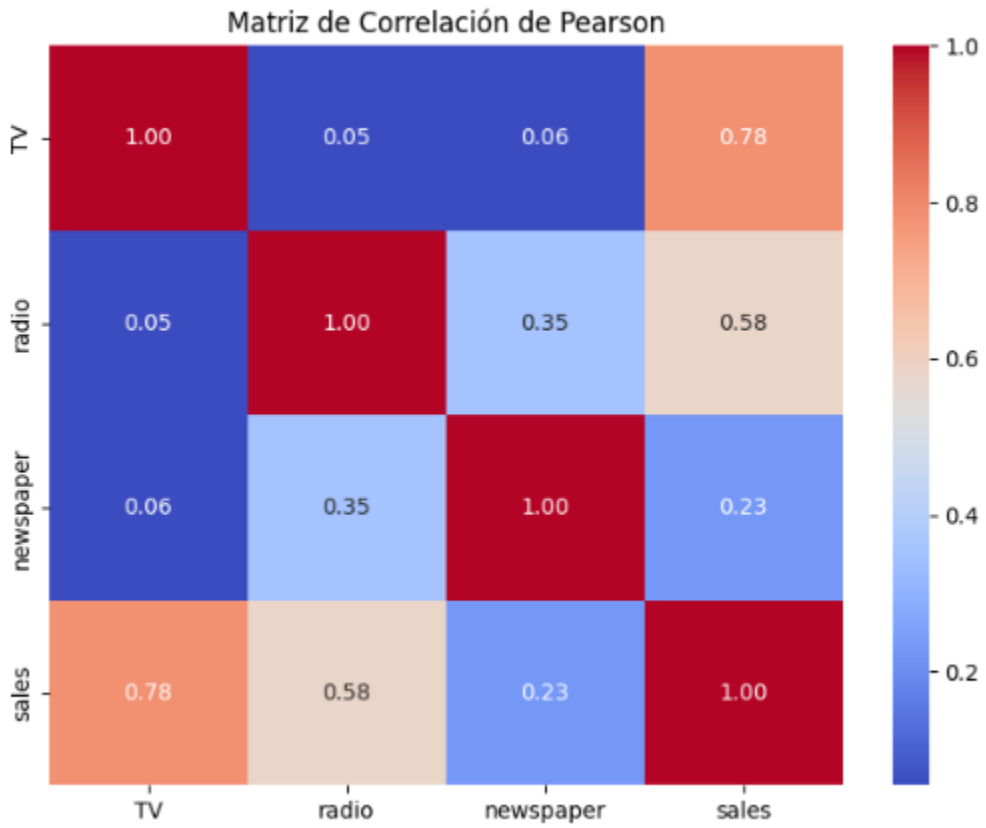


*Ilustración 9 correlación Pearson*

El coeficiente de correlación de Pearson nos permite establecer la fuerza y dirección de la conexión lineal entre un par de variables. En la matriz presentada se obtienen los siguientes datos:

- TV - Sales (r = 0,78): Se interpreta como que existe una correlación positiva fuerte entre ambas variables, señalando que a medida que la inversión publicitaria en teléfonos aumenta las ventas tienden a incrementarse.

- Radio - Sales (r = 0.58): La correlación se clasifica como positiva moderada, señalando que la publicidad en la radio también hace que las ventas se incrementen, aunque con menor intensidad que con la publicidad en televisión.
- Newspaper - Sales (r = 0.23): La correlación se sitúa en un nivel bajo, considerando que la inversión publicitaria en prensa tiene una correlación baja en términos de ventas.

Entre medios publicitarios: Correlaciones TV, Radio y Newspaper presentadas como bajas (0,05 - 0.35), indicando que las inversiones publicitarias de dichos medios no están fuertemente correlacionadas.

**Coeficiente de Spearman**

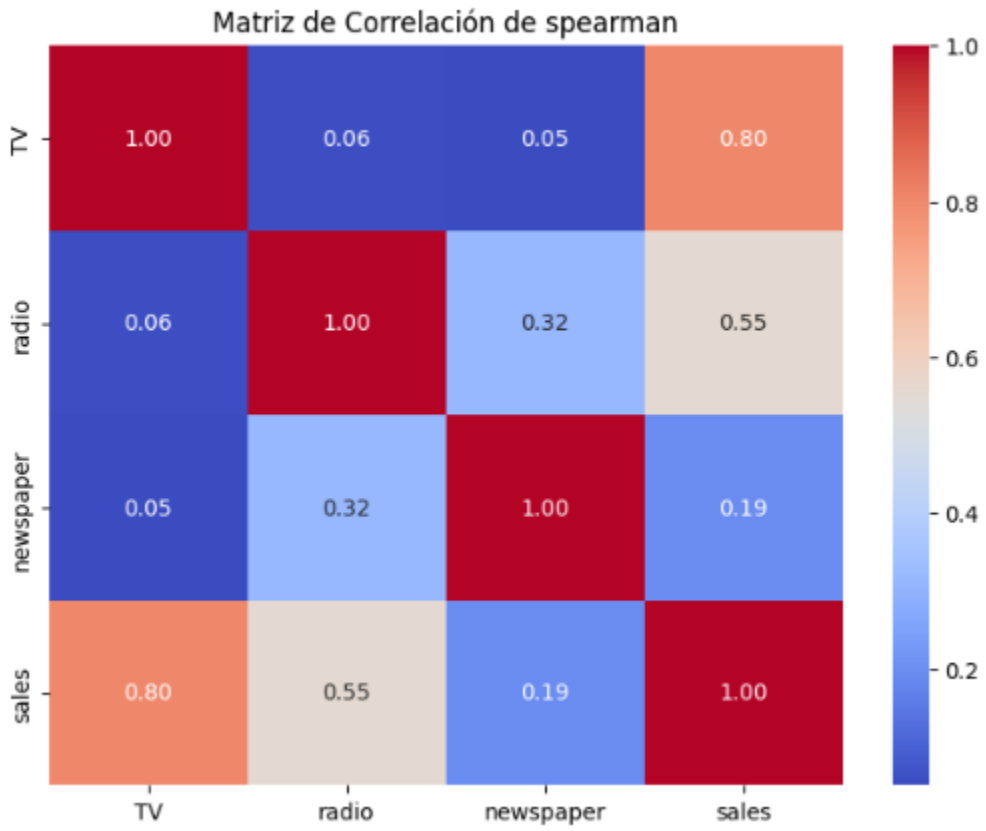


*Ilustración 10 correlacion de spearman*

El coeficiente de correlación de Spearman mide el grado como la dirección de la relación monotónica entre dos variables, y se utiliza los rangos en los que se encuentran los valores de los datos. En la matriz de correlaciones expuesta se puede concluir que:

- TV – Sales ($\rho = 0.80$): Existe una relación positiva alta, lo que significa que si se incrementa el presupuesto de inversión publicitaria en televisión, las ventas aumentan.
- Radio – Sales ($\rho = 0.55$): Es una relación positiva media, lo que supondría que la publicidad en radio va con el aumento de las ventas.
- Newspaper – Sales ($\rho = 0.19$): Hay una relación positiva baja, lo que significa que realizar inversiones publicitarias en periódicos se relaciona de una forma más débil con las ventas.

Entre los medios publicitarios: Las correlaciones entre TV, Radio y Newspaper son bajas (0.05 – 0.32), lo que indica que las inversiones en estos medios no están asociadas entre sí.

**Interpretación de resultados**

Cuando el coeficiente de correlación se aproxima a 1 o a –1, se puede afirmar que la relación entre las dos variables es fuerte. En este sentido, un coeficiente próximo a 1 quiere decir que la mayor inversión publicitaria se relaciona con mayores ventas. Un valor cercano a 0 denota que no existe relación apreciable entre la inversión en ese medio y las ventas. Si se comparan los coeficientes propia de Pearson y de Spearman, los resultados obtenidos son similares; esto es un indicio de que la relación entre las variables es principalmente lineal, lo que indica que no hay patrones complejos en los datos y un modelo de regresión lineal simple puede explicar adecuadamente esta relación.

**Fase 2: Regresión Lineal y Diagnóstico**

Al estimar el modelo de regresión lineal múltiple en Python utilizando el dataset Advertising, se obtuvieron los siguientes coeficientes:

| Parámetro | Valor estimado |
|---|---|
| Intercepto ($\hat{\beta}0$) | **29.389** |
| TV ($\hat{\beta}1$) | **0.0458** |
| Radio ($\hat{\beta}2$) | **0.1885** |
| Newspaper ($\hat{\beta}3$) | **-0.0010** |

Por lo tanto, el modelo estimado es:

Sales = 2.9389 + 0.0458 (TV) + 0.1885 (Radio) – 0.0010 (Newspaper)

Sales = 2.9389 + 0.0458 (TV) + 0.1885 (Radio) – 0.0010 (Newspaper) Sales = 2.9389 + 0.0458 (TV) +0.1885 (Radio) – 0.0010 (Newspaper)

**Interpretación del coeficiente de TV ($\hat{\beta}1$)**

El coeficiente de TV es 0.0458.

Esto significa que:

Si la inversión en publicidad en TV aumenta en una unidad, las ventas promedio aumentan aproximadamente 0.0458 unidades, manteniendo constantes las inversiones en radio y periódico.

Esto muestra que la publicidad en televisión tiene una relación positiva con las ventas.

**Interpretación del coeficiente de Radio (β̂2)**

El coeficiente de Radio es 0.1885.

Esto indica que:

Si la inversión en radio aumenta en una unidad, las ventas promedio aumentan aproximadamente 0.1885 unidades, manteniendo constantes las demás variables.

Comparando los coeficientes, se observa que la publicidad en radio tiene un efecto marginal mayor sobre las ventas que la televisión dentro de este modelo.

**Interpretación del coeficiente de Newspaper (β̂3)**

El coeficiente de Newspaper es -0.0010.

Esto significa que:

Un incremento de una unidad en la inversión en periódico generaría una disminución aproximada de 0.001 unidades en ventas, manteniendo constantes las demás variables.

Este efecto es muy pequeño y cercano a cero, lo que sugiere que la publicidad en periódicos tiene poca o ninguna influencia significativa sobre las ventas en comparación con los otros medios.

**Interpretación del intercepto (β̂0)**

El intercepto estimado es 2.9389, lo que indica que si la inversión en TV, Radio y Newspaper fuera igual a cero, el modelo predice aproximadamente 2.94 unidades de ventas.

Desde el punto de vista conceptual, este valor puede interpretarse como un nivel base de ventas, posiblemente asociado a factores externos como reconocimiento de marca, ventas orgánicas o demanda natural del mercado.

Sin embargo, en la práctica no es completamente realista que la inversión publicitaria sea exactamente cero, por lo cual el intercepto funciona principalmente como punto de ajuste del modelo.

**Análisis de Bondad de Ajuste**

El modelo presenta un coeficiente de determinación:

$$R^2 = 0.897$$

Esto significa que:

El 89.7% de la variabilidad total de las ventas es explicada por el modelo, utilizando como variables explicativas la inversión en TV, Radio y Newspaper.

Comparación con el modelo simple (Fase 1)

En la regresión simple usando solo TV, el valor de $R^2$era aproximadamente:

$$R^2 \approx 0.61$$

Esto indica que la inversión en televisión explicaba alrededor del 61% de la variabilidad de las ventas.

Al incluir Radio y Newspaper, el $R^2$aumenta a 0.897, lo que representa una mejora significativa en la capacidad explicativa del modelo.

No obstante, el análisis de coeficientes muestra que:

- Radio contribuye significativamente al modelo
- Newspaper tiene una influencia muy baja

Por lo tanto, la mejora del ajuste se debe principalmente a la incorporación de la variable Radio.

**estimación Matricial**

Matriz respuesta X′

X′ = ( 1 1  1 2  1 1  3 4  1 5 )

Producto X′X y su inversa (X′X) −1.

X′ X= (5 15 15 55 )

La determinante es: | X′ X | = 5 (55) – 15 (15) = 50

$$(X'X)^{-1} = \frac{1}{50} \quad (55 \ -15 \ -15 \ 5\ )$$

Producto $X'Y$

$$X'Y = (28\ 102\ )$$

Vector de parámetros βy

$$\beta = (X'X)^{-1}X'Y$$

$$\beta \ = (1.1\ 1.7\ )$$

**Referencias Bibliográficas**


- YouTube. (s.f.). *Árboles de decisión*. YouTube. https://youtu.be/INhSdlqYGfY

- https://colab.research.google.com/drive/1QWhABUnFk1gw7RWEquF4O-PKPAky3Ej4#scrollTo=Qupz0OfqUcO5

- • Anderson, D. R., Sweeney, D. J., & Williams, T. A. (2016). *Estadística para administración y economía* (12.ª ed.). Cengage Learning.
- • Lind, D. A., Marchal, W. G., & Wathen, S. A. (2015). *Estadística aplicada a los negocios y la economía* (16.ª ed.). McGraw-Hill Education.
- • Triola, M. F. (2018). *Estadística* (12.ª ed.). Pearson Educación.
- • Martínez Bencardino, C. (2012). *Estadística y muestreo*. Ecoe Ediciones.
- • Devore, J. L. (2016). *Probabilidad y estadística para ingeniería y ciencias* (9.ª ed.). Cengage Learning.