Taller 1: Análisis Predictivo y Aprendizaje Estadístico

Caso de Estudio: Advertising Data

Integrantes

ELKIN DANIEL RAMOS RODRIGUEZ 78158

VALENTINA ZARATE PERDOMO 114109

Docente

FREDY ALEXANDER ORJUELA LOPEZ

Sistemas Avanzados de Producción

Ingeniería Industrial

Bogotá, 2026

Índice

Introducción 3
Desarrollo Tecnico 3
2.1. Fase 1: Estadística Descriptiva y Análisis Exploratorio 3
2.1.1. Caracterización Numérica 3
2.1.2. Análisis de Distribución y Atípicos 4
2.1.3. Exploración de la Nube de Puntos 7
2.1.4. Evaluación de Asociación 11
2.1.4.1. Interpretación de Resultados 13
2.2. Fase 2: Regresión Lineal y Diagnóstico 14

Introducción

En entornos industriales y comerciales altamente competitivos, la toma de decisiones basada en datos se convierte en un elemento estratégico fundamental. Una de las preguntas más recurrentes en análisis de negocios es determinar el impacto real de la inversión publicitaria sobre las ventas.

El presente documentos analiza el conjunto de datos Advertising, compuesto por 200 mercados distintos, donde se registran inversiones en tres canales publicitarios (TV, Radio y Newspaper) y su correspondiente volumen de ventas. Nuestro punto principal es identificar la existencia de una asociación significativa entre publicidad y ventas, cuantificar la magnitud del efecto de cada medio, evaluar la capacidad predictiva de modelos lineales y no paramétricos y comparar la robustez entre regresión lineal y árboles de decisión.

Desarrollo Técnico

2.1. Fase 1: Estadística Descriptiva y Análisis Exploratorio

2.1.1. Caracterización Numérica

Las estadísticas descriptivas reales del dataset Advertising son:

Tabla 1. *Medidas de Tendencia Central y Dispersión de Variables Independientes y Variable Dependiente Sales*

Variable	Mean	Media	STD	Min	Max	Skewness	Kurtosis
TV	147.0425	149.75	85.854236	0.7	296.4	-0.069853	-1.226495
Radio	23.2640	22.90	14.846809	0.0	49.6	0.094175	-1.260401
Newspaper	30.5540	25.75	21.778621	0.3	114.0	0.894720	0.649502
Sales	14.0225	12.90	5.217457	1.6	27.0	0.407571	-0.408869

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB

2.1.2. Análisis de Distribución y Atípicos

El análisis del coeficiente de asimetría (Skewness) permite evaluar la forma de la distribución de cada variable y determinar si existen concentraciones de datos hacia alguno de los extremos. Para realizar el análisis de nuestros datos tenemos en cuenta:

$$Skewness \approx 0 \rightarrow Distribución\ aproximadamente\ simétrica$$
$$Skewness > 0 \rightarrow Sesgo\ positivo\ (cola\ hacia\ la\ derecha\ )Skewness < 0 \rightarrow Sesgo\ negativo\ (cola\ hacia\ la\ izquierda\ )$$

Entonces con esto, tenemos en cuenta la regla práctica:

$$|Skew| < 0{,}5 \rightarrow Aproximadamente\ simétrica$$
$$0{,}5 \leq |Skew| < 1 \rightarrow Moderadamente\ sesgada$$
$$|Skew| \geq 1 \rightarrow Altamente\ sesgada$$

En nuestro caso, la variable TV, se obtuvo un coeficiente de sesgo de -0.069853, valor muy cercano a cero. Esto indica que la distribución de la inversión en televisión es prácticamente simétrica, con una ligera inclinación hacia la izquierda que resulta estadísticamente irrelevante donde se entiende que la mayoría de los mercados presentan niveles de inversión relativamente equilibrados alrededor de la media.

Ilustración 1. *Histograma y Diagrama de Caja (Box Plot) para Variable TV*

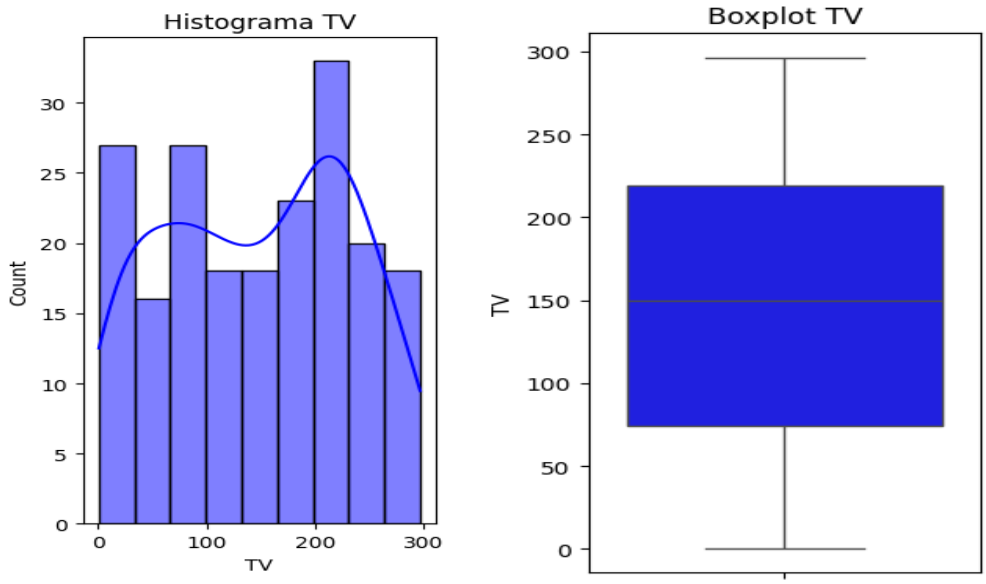

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB

La variable Radio presenta un coeficiente de sesgo de 0.094175, también muy cercano a cero, lo que indica una distribución prácticamente simétrica con una ligera asimetría positiva. Esto sugiere que existen algunos mercados con inversiones ligeramente superiores al promedio, pero no en magnitud suficiente.

Ilustración 2. *Histograma y Diagrama de Caja (Box Plot) para Variable Radio*

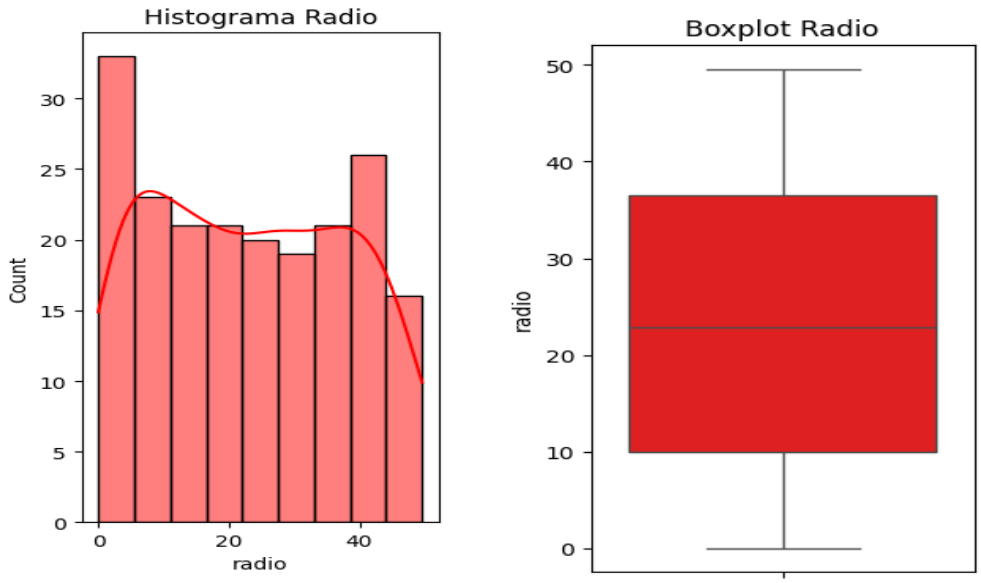

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB

La variable Newspaper presenta un coeficiente de sesgo de 0.894720, lo que indica una asimetría positiva moderada. Esto significa que la mayoría de los mercados realizan inversiones relativamente bajas en periódicos, mientras que un grupo reducido concentra inversiones considerablemente más altas.

Ilustración 3. *Histograma y Diagrama de Caja (Box Plot) para Variable Newspaper*

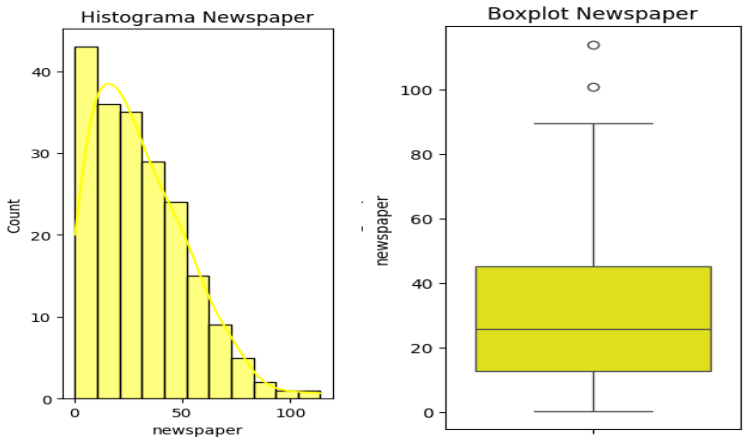

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB

La variable Newspaper presenta un coeficiente de sesgo de 0.894720, lo que indica una asimetría positiva moderada. Esto significa que la mayoría de los mercados realizan inversiones relativamente bajas en periódicos, mientras que un grupo reducido concentra inversiones considerablemente más altas

Ilustración 4. *Histograma y Diagrama de Caja (Box Plot) para Variable Sales*

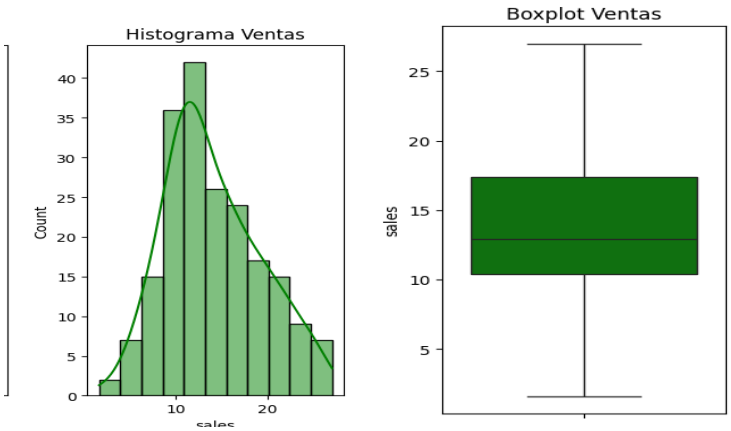

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB

¿Se identifican datos atípicos o observaciones que se alejan significativamente de la masa de los datos?

A partir del análisis exploratorio mediante diagramas de caja y la evaluación del sesgo, se identifican posibles valores atípicos principalmente en la variable Newspaper, donde existen inversiones significativamente superiores al resto de la muestra. También pueden observarse algunos valores altos en TV, aunque en menor proporción. Estas observaciones se alejan de la masa principal de los datos y pueden ejercer una influencia desproporcionada en la estimación de los parámetros del modelo lineal.

Lo que indica que, si se identifican posibles valores atípicos, especialmente en Newspaper, su influencia no parece ser lo suficientemente fuerte como para invalidar el modelo lineal múltiple, aunque sí justifican un análisis cuidadoso de los residuos y de la estabilidad de los coeficientes estimados.

2.1.3. Exploración de la Nube de Puntos

Con el fin de identificar la naturaleza de la relación entre la variable respuesta (Sales) y cada covariable (TV, Radio y Newspaper), se construyeron diagramas de dispersión (scatter plots) donde el eje horizontal representa la inversión publicitaria y el eje vertical el volumen de ventas.

El análisis visual permite determinar si la relación parece lineal, no lineal, segmentada o si existen observaciones influyentes.

- Sales vs TV

Ilustración 5. *Diagramas de Dispersión (scatter plots) para Variables Sales vs TV.*

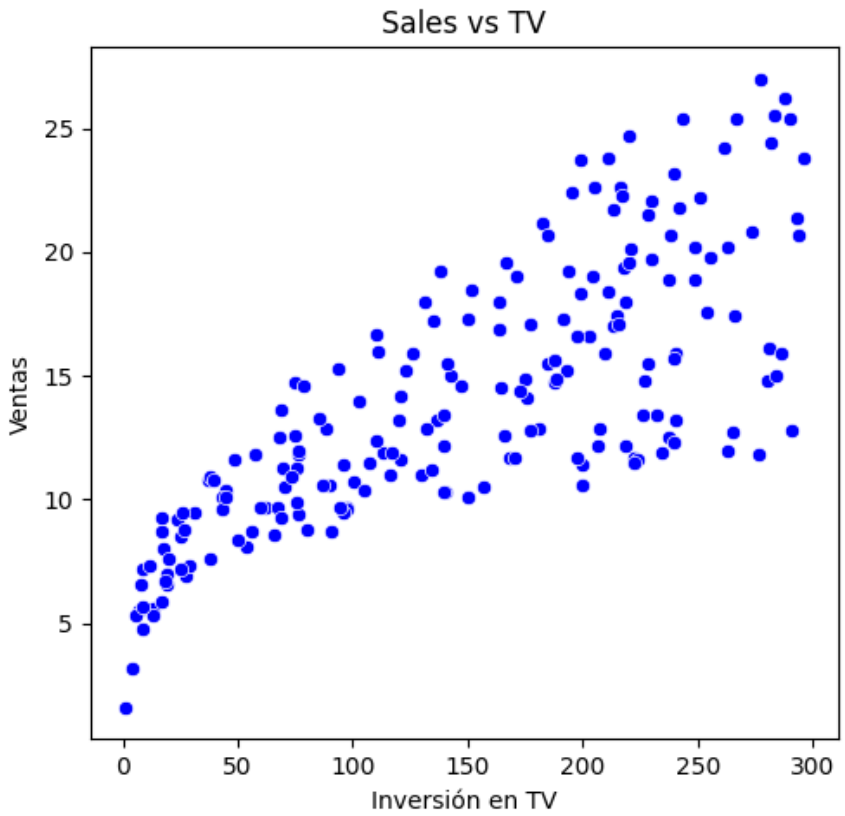

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB.

El dispersograma entre TV y Sales muestra una clara tendencia creciente aproximadamente lineal. A medida que la inversión en televisión aumenta, las ventas también tienden a incrementarse.

Se observa:

- Una nube de puntos con pendiente positiva.
- Dispersión relativamente homogénea.
- Ausencia de curvaturas pronunciadas.
- No se observan patrones parabólicos.

La relación entre TV y Sales puede modelarse adecuadamente mediante una regresión lineal simple, ya que la estructura de la nube de puntos respalda el supuesto de linealidad.

- Sales vs Radio

Ilustración 6. *Diagramas de Dispersión (scatter plots) para Variables Sales vs Radio.*

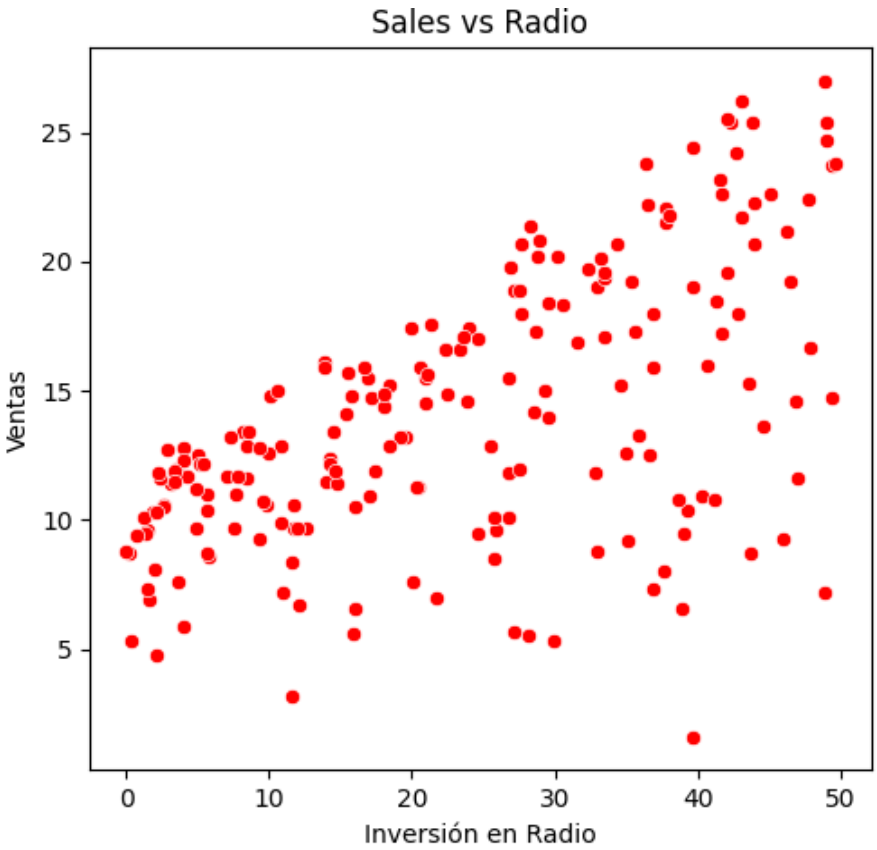

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB.

El dispersograma entre Radio y Sales también evidencia una relación positiva, aunque con mayor dispersión que en el caso de TV.

Se observa:

- Tendencia creciente clara.
- Mayor variabilidad vertical en niveles intermedios.
- Ausencia de forma parabólica o no lineal.

La relación es compatible con un modelo lineal, aunque ligeramente menos fuerte que la observada con TV. La dispersión sugiere que Radio influye en las ventas, pero no de forma tan dominante como TV.

- Sales vs Newspaper

Ilustración 7. *Diagramas de Dispersión (scatter plots) para Variables Sales vs Newspaper.*

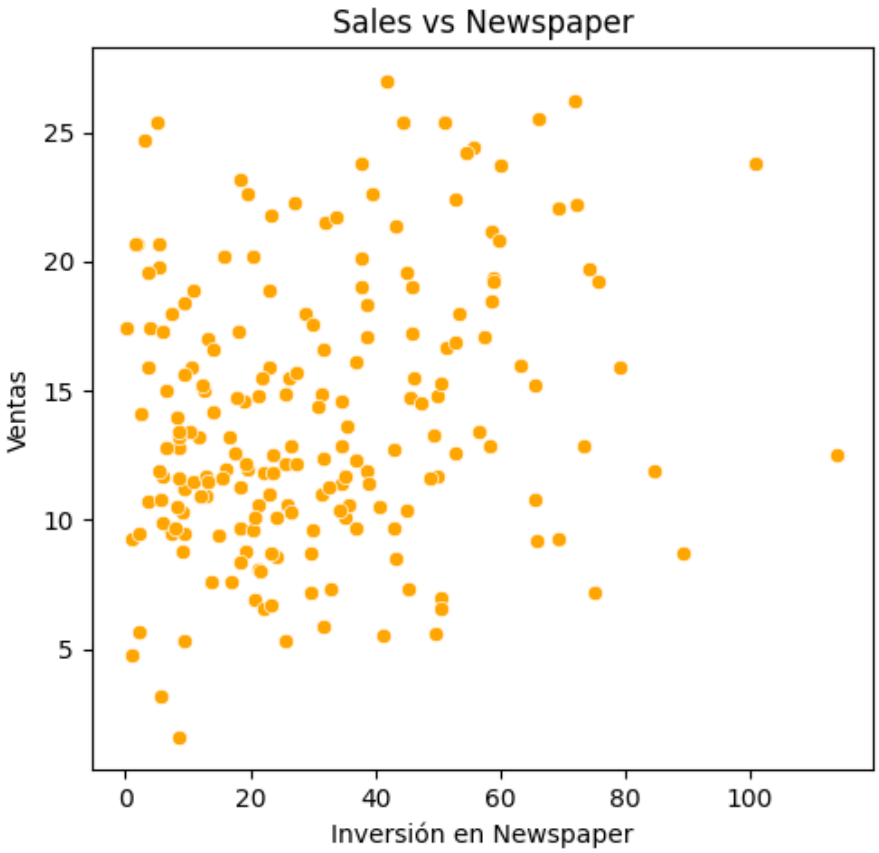

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB.

El dispersograma entre Newspaper y Sales presenta una estructura diferente:

- Alta dispersión de puntos.
- Ausencia de pendiente claramente definida.
- Concentración de observaciones en niveles bajos de inversión.
- Algunos valores altos aislados.

La relación entre Newspaper y Sales no parece lineal fuerte ni sistemática. Visualmente, no se justifica un modelo lineal simple con esta variable como único predictor.

2.1.4. Evaluación de Asociación

El coeficiente de Pearson mide la fuerza de la relación lineal entre dos variables continuas para nuestro caso podemos identificar la siguiente matriz:

Ilustración 8. *Matrices de Correlación de Pearson para de Variables Independientes y Variable Dependiente Sales.*

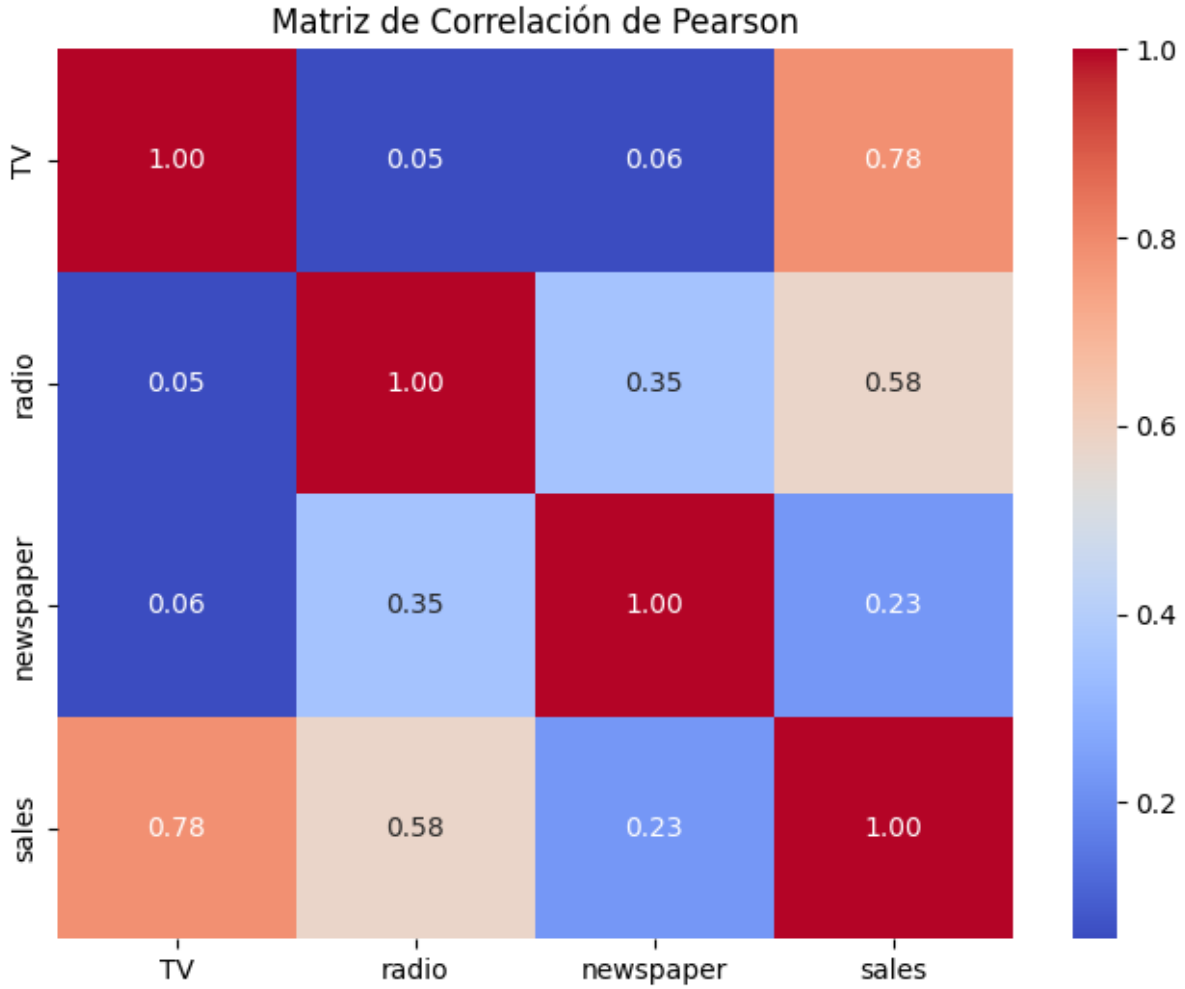

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB.

- TV – Sales (0.78)

Existe una fuerte asociación lineal positiva. A mayor inversión en televisión, mayores ventas. Este valor cercano a 1 indica que TV es el predictor con mayor relación directa con Sales.

- Radio – Sales (0.58):

Presenta una asociación lineal positiva moderada. Aunque menor que TV, sigue siendo relevante y estadísticamente significativa.

- Newspaper – Sales (0.23):

La relación es débil. Este valor cercano a 0 indica que la inversión en periódicos no explica de manera importante la variabilidad en ventas.

Adicionalmente, se observa que TV y Radio no están altamente correlacionadas entre sí (0.05), lo que reduce problemas de multicolinealidad en el modelo múltiple.

Ilustración 9. *Matrices de Correlación de Spearman para de Variables Independientes y Variable Dependiente Sales.*

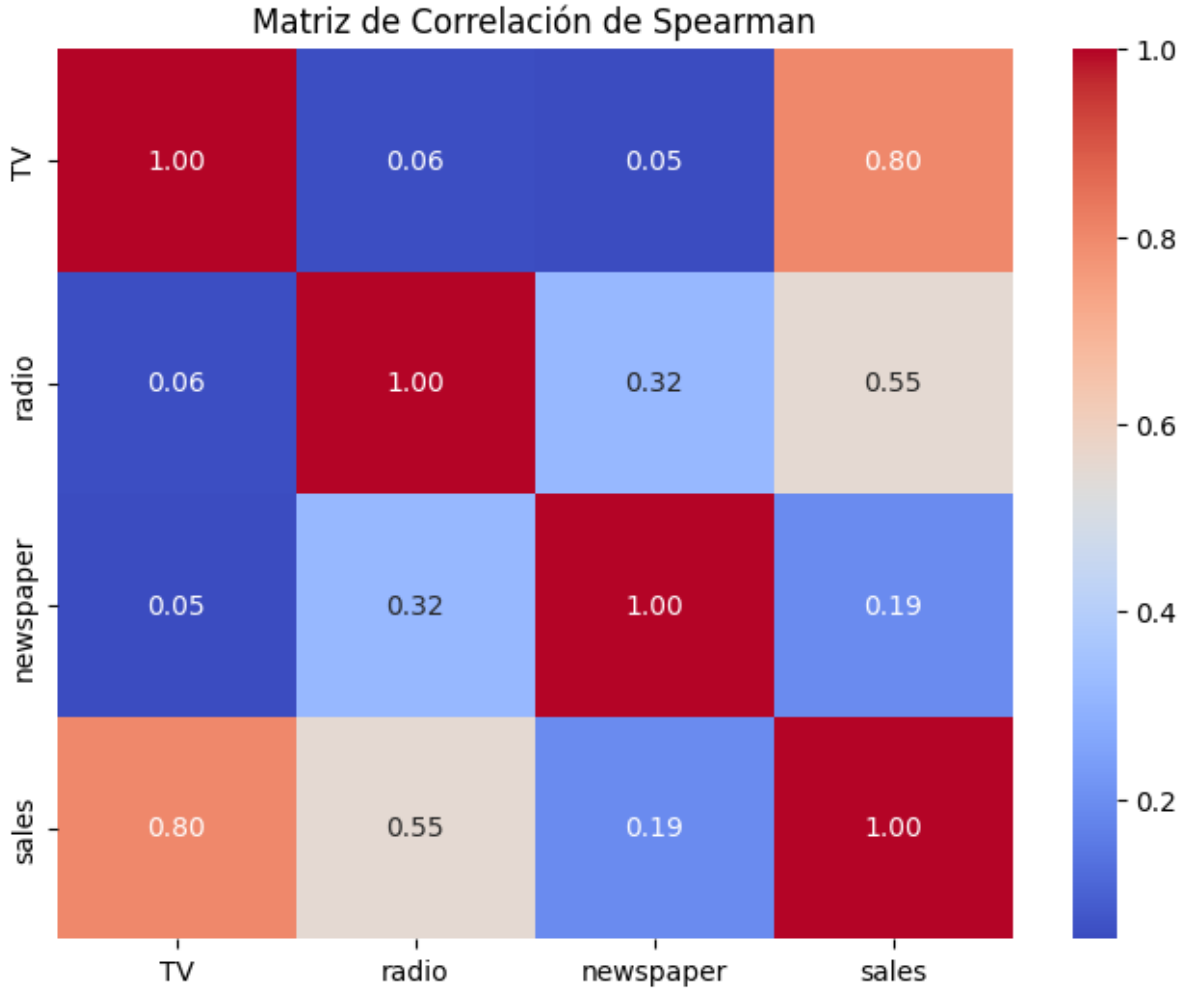

Nota. Tabla hecha por los estudiantes y desarrollada en COLAB.

La correlación de Spearman evalúa relaciones monótonas, basándose en los rangos de los datos en lugar de los valores originales. Si Spearman hubiera sido considerablemente mayor que Pearson, eso indicaría una relación no lineal pero monótona. No es el caso

Los resultados obtenidos son muy similares a los de Pearson:

- TV – Sales ≈ 0.80
- Radio – Sales ≈ 0.55–0.58
- Newspaper – Sales ≈ 0.20–0.25

El hecho de que los coeficientes de Spearman sean muy similares a los de Pearson indica que:

- La relación entre las variables es esencialmente lineal.
- No existen patrones no lineales fuertes.
- No se identifican relaciones monótonas complejas que no sean lineales.

2.1.4.1. Interpretación de Resultados

- ¿Qué significa un coeficiente cercano a 1 o −1 en el contexto de la inversión publicitaria y el retorno en ventas?

  Un coeficiente cercano a 1 se entiende como una fuerte asociación positiva: cuando la inversión aumenta, las ventas tienden a aumentar proporcionalmente.

  En cambio, un coeficiente cercano a -1 indicaría una relación inversa fuerte, donde un aumento en una variable implicaría disminución en la otra. En este caso no se observan relaciones negativas relevantes.

- ¿Cómo se interpreta un valor de correlación cercano a 0?

  Un valor cercano a 0 se entiende como ausencia de relación lineal significativa. En nuestro caso, Newspaper presenta una correlación baja con Sales, lo que sugiere bajo poder explicativo.

- Compare ambos coeficientes (Pearson y Spearman). ¿Sugieren estos resultados que las relaciones son estrictamente lineales?

Dado que los coeficientes de Pearson y Spearman son muy similares y que la nube de puntos no muestra curvaturas pronunciadas, se concluye que las relaciones son predominantemente lineales.

2.2. Fase 2: Regresión Lineal y Diagnóstico

2.2.1. Modelamiento Múltiple e Interpretación

Se estimó un modelo de regresión lineal múltiple de la siguiente forma:

$$Sales = \beta_0 + \beta_1 TV + \beta_2 Radio + \beta_3 Newspaper \quad (1)$$

dónde Sales representa el volumen de ventas (en miles de unidades), mientras que TV, Radio y Newspaper corresponden a la inversión publicitaria en miles de dólares en cada medio.

La estimación se realizó mediante el método de Mínimos Cuadrados Ordinarios, el cual minimiza la suma de los errores al cuadrado:

$$RSS = \Sigma(y_i - \hat{y}_i)^2 \quad (2)$$

Los resultados obtenidos en Colab fueron los siguientes:

- Intercepto (β_0): 2.9389
- Coeficiente TV (β_1): 0.0458
- Coeficiente Radio (β_2): 0.1885
- Coeficiente Newspaper (β_3): -0.0010

Por lo tanto, la ecuación estimada del modelo es:

$$\widehat{Sales} = 2.9389 + 0.0458TV + 0.1885Radio - 0.0010Newspaper \quad (3)$$

Desde lo matemático, el intercepto se debe ajustar para el plano de regresión. Sin embargo, en la realidad es un poco realista ya que si lo interpretamos sería un mercado sin ningún tipo de herramienta publicitaria. Por otro lado, puede interpretarse como el nivel base de ventas atribuible a factores estructurales como posicionamiento de marca, distribución o demanda natural del producto.

Por lo tanto, aunque no represente una situación común en la práctica, sí tiene sentido conceptual como punto de referencia del modelo.

2.2.2. Interpretación de Parámetros

Interpretación del intercepto (β_0):

El intercepto estimado del modelo es:

$$(\beta_0): 2.9389$$

Este valor representa el nivel esperado de ventas cuando la inversión en TV, Radio y Newspaper es igual a cero.

Aunque este escenario no es completamente realista desde el punto de vista operativo ya que normalmente existe algún tipo de publicidad, sí tiene sentido conceptual, pues puede interpretarse como el nivel base de ventas explicado por factores no incluidos en el modelo, tales como:

- Reconocimiento previo de la marca
- Canales de distribución
- Lealtad de los clientes
- Demanda natural del producto

Por lo tanto, que el intercepto sea distinto de cero es coherente y necesario para ajustar adecuadamente el plano de regresión.

Interpretación de los coeficientes $\beta_1, \beta_2, \beta_3$

- Coeficiente TV (β_1): 0.0458

Manteniendo constantes Radio y Newspaper, un aumento de una unidad en la inversión en TV (mil dólares) se asocia con un incremento promedio de 0.0458 unidades en las ventas (miles de unidades).
Esto afirma que la publicidad en televisión presenta un impacto positivo y significativo sobre las ventas generadas.

- Coeficiente Radio (β_2): 0.1885

Manteniendo constantes TV y Newspaper, un incremento unitario en Radio genera un aumento promedio de 0.1885 unidades en las ventas.
Este coeficiente es mayor que el de TV, lo que sugiere que, marginalmente, Radio puede ser demasiado eficiente en algunos rangos de inversión.

- Coeficiente Newspaper (β_3): -0.0010

Manteniendo constantes TV y Radio, el coeficiente negativo indica que la inversión en Newspaper no contribuye de manera significativa al incremento de las ventas.
Su efecto es nulo y consistente con el análisis exploratorio y de correlación realizado en la Fase # 1.

2.2.3. Análisis de Bondad de Ajuste

Coeficiente de determinación R^2
El coeficiente de determinación obtenido del modelo múltiple indica que:

$$R^2 \approx 0.90$$

Esto significa que aproximadamente el 90 % de la variabilidad total de las ventas es explicada por el modelo implementado, utilizando las variables TV, Radio y Newspaper.

Análisis de radio y Newspaper

En comparación con el modelo simple de la Fase # 1 (Sales vs TV), la inclusión de Radio mejora significativamente el ajuste del modelo.

La variable Newspaper, en cambio, no aporta una mejora significante al ajuste, lo cual es coherente con:

- Su baja correlación con Sales
- Su coeficiente cercano a cero
- La alta dispersión observada en el scatter plot

Se puede concluir que el Radio sí mejora el modelo, mientras que Newspaper tiene un aporte marginal, y podría considerarse su exclusión en modelos más parsimoniosos.

2.2.4. estimación Matricial

Matriz respuesta X'

a) X' = $\begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix}$

b) Producto X′ X y su inversa (X′ X) −1.

X' X= $\begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}$

La determinante es: | X' X | = 5 (55) – 15 (15) = 50

$$(X'X)^{-1} = \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix}$$

c) Producto $X'Y$

$$X'Y = \begin{pmatrix} 28 \\ 102 \end{pmatrix}$$

d) vector de parámetros βy

$$\beta = (X'X)^{-1}X'Y$$

$$\beta = \begin{pmatrix} 1.1 \\ 1.7 \end{pmatrix}$$

e) Ecuación de la recta estimada

$$Y = 1.1 + 1.7\,x$$

Conclusiones

El análisis confirma que ha tenido un impacto significativo la inversión publicitaria predominantemente lineal sobre las ventas. Se consolida la televisión como el mayor medio asociado global, mientras que la radio demuestra una alta eficiencia marginal dentro del modelo múltiple.

Por lo contrario, al momento de inversión en periódicos no genera ni se evidencia un aporte significativo en las ventas, por lo que la inclusión en el modelo resulta muy poco relevante desde una perspectiva predictiva.

En el modelo de regresión lineal múltiple presenta un alto poder explicativo, en lo que valida utilidad como herramienta para la toma de una decisión estratégica y una asignación optima del presupuesto publicitario